

Detecção Não Supervisionada de Anomalias em Séries Temporais Financeiras Brasileiras com LSTM-Autoencoder

Ana Beatriz and Miguel Cerne

Redes Neurais (2026.1)

23 de junho de 2026

Resumo

A detecção de anomalias em mercados financeiros é dominada, na literatura, pelo mercado norte-americano e por criptomoedas. Este trabalho aplica uma arquitetura *LSTM-Autoencoder* à detecção não supervisionada de anomalias em quatro ações da B3 (PETR4, VALE3, AMER3 e ITUB4), cobrindo distintos setores econômicos. O modelo é treinado apenas sobre o período considerado de “normalidade” (2010–2019) e sinaliza como anômalas as janelas cujo erro de reconstrução excede um limiar; comparam-se limiares estático (percentil fixo) e dinâmico (percentil em janela móvel causal). A avaliação combina validação narrativa (sobreposição com eventos econômicos e políticos brasileiros documentados) e quantitativa (injeção controlada de anomalias sintéticas, com Precision, Recall e F1). Este relatório preliminar documenta, de forma incremental e academicamente rastreável, as decisões metodológicas, suas fontes e as observações de cada etapa do projeto. Até o momento concluíram-se as etapas de *infraestrutura* (M0) e de *coleta e análise exploratória* (M1).

Palavras-chave: detecção de anomalias; LSTM-Autoencoder; séries temporais financeiras; B3; aprendizado não supervisionado.

Sumário

1	Introdução	2
1.1	Contribuições	3
1.2	Ativos e período	3
1.3	Sobre este documento	3
2	Trabalhos Relacionados	3
3	Metodologia	4
3.1	Pré-processamento	4
3.2	Modelo	4
3.3	Detecção	4
3.4	Avaliação	4
4	M0 — Infraestrutura e Reprodutibilidade	4
4.1	Ambiente e dependências	5
4.2	Configuração centralizada e seeds	5
4.3	Decisões de hiperparâmetros e proveniência	5
4.4	Riscos metodológicos registrados	5

5	M1 — Coleta e Análise Exploratória	6
5.1	Coleta e cache	6
5.2	Integridade das séries	6
5.3	Anomalias reais identificadas	6
5.4	O caso AMER3	6
6	M2 — Pré-processamento	7
6.1	Log-retornos	7
6.2	Split temporal e normalização	7
6.3	Revisão da hipótese sobre o AMER3	7
7	M3 — Modelo e Treino	7
7.1	Arquitetura	7
7.2	Protocolo de treino	8
7.3	Sensibilidade do gargalo	8
7.4	Baseline de comparação	8
7.5	Erro de reconstrução	8
8	M4 — Detecção e Limiares	8
8.1	Erro de reconstrução	8
8.2	Limiar estático	8
8.3	Limiar dinâmico	9
8.4	Comparação empírica	9
8.5	Sensibilidade da janela dinâmica	9
9	M5 — Avaliação Quantitativa por Injeção Sintética	9
9.1	Motivação e desenho	9
9.2	Regra de rotulagem por janela	10
9.3	Resultados	10
9.4	Leitura crítica	11
9.5	Calibração relativa $k\sigma$	12
10	M6 — Correlação com Eventos e Comparação Setorial	12
10.1	Validação narrativa	12
10.2	Comparação setorial	13
10.3	Contágio sistêmico: o teste da COVID	13
11	Limitações e Validade	14
11.1	O período de treino “normal” não é livre de anomalias	14
11.2	Demais limitações	14
12	Reprodutibilidade e Entrega	15
13	Conclusões Parciais e Próximos Passos	15

1 Introdução

A identificação de comportamentos atípicos em séries de preços de ativos é relevante tanto para a gestão de risco quanto para a compreensão de como eventos econômicos e políticos se refletem nos mercados. A maior parte da literatura de detecção de anomalias com aprendizado profundo concentra-se no mercado norte-americano e em criptomoedas [3, 4], deixando sub-representado o contexto de mercados emergentes como o brasileiro.

Este trabalho investiga a detecção *não supervisionada* de anomalias em ações da B3 por meio de um *LSTM-Autoencoder* [2]. A premissa é que um autoencoder treinado apenas em períodos de comportamento típico aprende a reconstruir os padrões normais da série; diante de movimentos atípicos, o erro de reconstrução cresce e sinaliza a anomalia.

1.1 Contribuições

O projeto combina quatro contribuições:

1. Aplicação a ativos nacionais (B3), contexto sub-representado na literatura.
2. Correlação sistemática e documentada entre anomalias detectadas e eventos históricos brasileiros.
3. Comparação entre limiar *estático* (percentil fixo) e *dinâmico* (percentil em janela móvel).
4. Avaliação de generalização entre setores econômicos distintos.

1.2 Ativos e período

Foram selecionados quatro ativos, um por setor, conforme a Tabela 1. O período de coleta vai de 2010 a 2024; o treino (“normalidade”) usa 2010–2019 e o teste, 2020–2024.

Tabela 1: Ativos analisados.

Ticker	Empresa	Setor
PETR4.SA	Petrobras PN	Energia/commodities
VALE3.SA	Vale S.A.	Mineração
AMER3.SA	Americanas S.A.	Varejo
ITUB4.SA	Itaú Unibanco	Financeiro

1.3 Sobre este documento

Trata-se de um relatório preliminar e *vivo*: a cada fechamento de *milestone* acrescenta-se uma seção descrevendo, academicamente, as decisões tomadas, suas fontes, as observações empíricas e as conclusões parciais. As decisões de configuração são registradas em paralelo como *Architecture Decision Records* (ADRs) no repositório (`docs/adr/`), referenciados ao longo do texto.

2 Trabalhos Relacionados

A detecção de anomalias com autoencoders recorrentes baseia-se na ideia de que a reconstrução de padrões aprendidos falha sobre observações fora da distribuição de treino. Li [4], em referência amplamente reproduzida, aplica um LSTM-Autoencoder a preços de ações (Johnson & Johnson), adotando janelas de 30 passos de tempo e definindo o limiar de anomalia a partir do erro de reconstrução do treino. Valkov [7] fornece uma implementação canônica em Keras, com escolhas de projeto que servem de referência prática (camadas LSTM de 64 unidades, *dropout* de 0,2, `validation_split` de 0,1 e, crucialmente, `shuffle=False` para preservar a ordem temporal). Petrovic [6] disponibiliza um repositório com abordagem equivalente.

Trabalhos mais recentes ampliam o desenho experimental. Liu et al. [5] propõem um arcabouço híbrido que acopla um LSTM-Autoencoder a redes adversárias generativas e introduzem explicitamente um *mecanismo de injeção artificial de anomalias* para avaliação quantitativa, validado em múltiplas categorias de ações — desenho que inspira diretamente a avaliação setorial e por injeção adotada neste projeto. No domínio de criptomoedas, IEEE [3] exploram a mesma família de modelos sobre valores do Bitcoin.

Em relação a esses trabalhos, a principal lacuna endereçada aqui é a aplicação ao mercado brasileiro (B3) com correlação documentada a eventos nacionais e comparação explícita entre estratégias de limiar estático e dinâmico.

3 Metodologia

Esta seção descreve o desenho metodológico do projeto. Os valores numéricos de hiperparâmetros e suas justificativas são apresentados nas seções de cada *milestone* e consolidados nos ADRs do repositório.

3.1 Pré-processamento

A feature principal é o *retorno logarítmico diário*, $r_t = \ln(P_t/P_{t-1})$, sobre o preço de fechamento ajustado. Adota-se um **split temporal antes da normalização**: o `MinMaxScaler` é ajustado *apenas* sobre o treino e então aplicado ao teste, evitando vazamento de informação do futuro. A série é então segmentada em *janelas deslizantes* de tamanho fixo (ver Seção 5).

3.2 Modelo

A arquitetura é um *LSTM-Autoencoder* [2]: um codificador LSTM comprime a janela em uma representação latente (gargalo), e um decodificador LSTM reconstrói a sequência, otimizando o erro quadrático médio (MSE) de reconstrução. Treina-se **um modelo por ativo**, condição necessária para a comparação setorial.

3.3 Detecção

Uma janela é marcada como anômala quando seu erro de reconstrução ultrapassa um limiar. Comparam-se duas estratégias:

- **Estático:** percentil fixo (95) do erro de reconstrução do treino.
- **Dinâmico:** percentil em janela móvel *causal* (apenas o passado), sensível a mudanças de regime.

3.4 Avaliação

Por ser um problema não supervisionado, a avaliação combina duas vias [5]:

- **Narrativa:** verificação de que as anomalias detectadas correspondem a eventos reais conhecidos (e.g., *crash* de março/2020; caso Americanas em janeiro/2023).
- **Quantitativa:** injeção controlada de anomalias sintéticas (*price shocks* e *volume spikes*) em posições conhecidas, permitindo calcular Precision, Recall e F1.

Nota metodológica. O período de treino (2010–2019) contém eventos de forte volatilidade (recessão de 2014–2016, Operação Lava Jato, *impeachment* de 2016). A definição de “normalidade” é, portanto, relativa, e essa limitação é assumida explicitamente.

4 M0 — Infraestrutura e Reprodutibilidade

A primeira etapa estabeleceu a infraestrutura que garante reprodutibilidade e separação entre lógica e orquestração: a lógica reside em `src/` e os notebooks apenas orquestram e visualizam.

4.1 Ambiente e dependências

Fixou-se o interpretador em **Python 3.12.13** (via `pyenv`), versão idêntica à do Google Colab à época, alvo principal de execução. As dependências foram *pinadas* (TensorFlow/Keras [1], `yfinance`, `pandas`, `numpy`, `scikit-learn`, `matplotlib`, `seaborn`), habilitando instalação editável (`pip install -e .`). Notebooks têm suas saídas removidas automaticamente no versionamento (`nbstripout`), reduzindo ruído em *diffs*.

4.2 Configuração centralizada e seeds

Todos os hiperparâmetros residem em `config.yaml`, fonte única de verdade: alterar um experimento significa alterar esse arquivo, não os notebooks. O módulo `src/config.py` carrega essa configuração e expõe `set_seeds()`, que fixa as sementes de `random`, `numpy` e `tensorflow` para reprodutibilidade.

4.3 Decisões de hiperparâmetros e proveniência

Um princípio metodológico central do projeto é a **rastreabilidade da proveniência** de cada hiperparâmetro. Cada escolha é classificada como: *fundamentada* (ancorada no enunciado do projeto ou na literatura), *default de literatura* (convenção da implementação de referência), *decisão de projeto* (escolha de *design* sem fonte direta, com *rationale* explícito) ou *provisória* (valor a ser calibrado por experimento). A Tabela 2 consolida as principais decisões; os valores provisórios não devem sustentar resultados finais sem validação.

Tabela 2: Principais hiperparâmetros e sua proveniência (consolidado dos ADRs).

Parâmetro	Valor	Proveniência
<code>window_size</code>	30	Fundamentada [4, 7]
<code>lstm_units</code>	64	Default de literatura [7]
<code>dropout</code>	0,2	Default de literatura [7]
<code>latent_dim</code>	16	Decisão de projeto (calibrar)
<code>loss</code>	MSE	Fundamentada [4]
<code>shuffle</code>	False	Fundamentada (causalidade) [7]
<code>validation_split</code>	0,1	Default de literatura [7]
<code>threshold_percentile</code>	95	Fundamentada (enunciado)
<code>dynamic_window</code>	252	Provisória (≈ 1 ano útil)
<code>n_injections</code>	50	Provisória

4.4 Riscos metodológicos registrados

Três riscos foram documentados já nesta fase, para serem honrados na implementação: (i) o `validation_split` do Keras separa o *bloco final* dos dados antes de embaralhar — logo `shuffle=False` é obrigatório, sob pena de vazamento temporal; (ii) o limiar dinâmico deve ser *causal*, usando apenas observações passadas; (iii) o `MinMaxScaler` ajustado no treino faz com que extremos do teste possam exceder o intervalo $[0, 1]$ — comportamento esperado e desejável, pois é onde residem as anomalias, mas que torna o limiar sensível a *outliers* isolados (motivando o uso de percentil em vez do máximo).

5 M1 — Coleta e Análise Exploratória

5.1 Coleta e cache

Os dados são obtidos via `yfinance` com `auto_adjust=True`, de modo que o preço de fechamento já incorpora ajustes por *splits* e dividendos. A arquitetura de dados separa estritamente o acesso à rede da leitura: as funções `cache_*` baixam e persistem os dados em `data/raw/` (CSV, versionado), enquanto `load_*` — usadas por todo o *pipeline* — leem apenas do cache, jamais da API. Isso garante execução *offline* e reproduzível dos notebooks.

5.2 Integridade das séries

As quatro séries apresentam **3724 pregões** cada (2010-01-04 a 2024-12-30), sem valores ausentes (NaN) após o ajuste. A Tabela 3 resume os achados. A função `integrity_report` computa, por ativo, contagens de NaN, dias com volume zero (halts/iliquidez) e os extremos de log-retorno diário, que funcionam como indicadores tanto de anomalias reais quanto de eventuais artefatos.

Tabela 3: Integridade e maior queda diária de log-retorno por ativo.

Ticker	Pregões	NaN	Vol. zero	Maior queda (data)
PETR4.SA	3724	0	54	−0,352 (2020-03-09)
VALE3.SA	3724	0	27	−0,282 (2019-01-28)
AMER3.SA	3724	0	25	−1,484 (2023-01-12)
ITUB4.SA	3724	0	34	−0,198 (2021-10-04)

5.3 Anomalias reais identificadas

A EDA já revela eventos extremos que servirão de âncora para a validação narrativa (M6):

- **PETR4**, 09/03/2020: queda associada ao início da pandemia de COVID-19 e à guerra de preços do petróleo.
- **VALE3**, 28/01/2019: reação ao rompimento da barragem de Brumadinho.
- **AMER3**, 12/01/2023: divulgação da fraude contábil da Americanas (queda de $\approx 78\%$ no dia).
- **ITUB4**, 04/10/2021: maior queda do setor financeiro no período.

A distribuição dos log-retornos exhibe caudas pesadas (leptocurtose), o que reforça a escolha de limiares por percentil em vez de critérios baseados em desvio-padrão.

5.4 O caso AMER3

A série da Americanas merecia atenção especial por causa da reorganização societária e do colapso pós-fraude. Dois pontos foram esclarecidos pela EDA:

1. **Histórico de treino existe.** Diferentemente da hipótese inicial de ausência de dados em 2010–2019, o `yfinance` fornece a série desde 2010 por continuidade de *ticker* (herdada da Lojas Americanas). Há, portanto, dados de “normalidade” para o ativo.
2. **Sinal vs. artefato.** A queda de 12/01/2023 é uma anomalia *real* e deve ser preservada (é justamente o evento-alvo). Já o salto de log-retorno $\approx +1,03$ em 14/11/2024 é compatível com um *grupamento* (*reverse split*) não totalmente ajustado pela fonte, configurando provável **artefato**.

Decidiu-se, para a etapa de pré-processamento (M2), **corrigir o fator de grupamento** do AMER3, em vez de recortar o período — preservando a continuidade temporal e o caso completo do ativo.

6 M2 — Pré-processamento

Esta etapa transforma as séries de preço na representação consumida pelo modelo, respeitando a ordem metodológica que evita vazamento temporal (Seção 3).

6.1 Log-retornos

A feature principal é o retorno logarítmico diário $r_t = \ln(P_t/P_{t-1})$, calculado sobre o fechamento ajustado. Por ser invariante a transformações multiplicativas de escala, é imune a fatores de *split*/grupamento já aplicados ao preço — propriedade relevante para o caso AMER3 (Seção 6.3).

6.2 Split temporal e normalização

Aplica-se primeiro o *split* temporal (treino até 2019; teste a partir de 2020) e só então a normalização: o `MinMaxScaler` é ajustado *exclusivamente* no treino e aplicado a ambas as partições. Como consequência esperada, uma fração dos pontos de teste extrapola o intervalo $[0, 1]$ — precisamente os extremos pós-2020 fora da faixa observada no treino. Esse comportamento é desejável: é onde se concentram as anomalias, e o erro de reconstrução tende a crescer ali. As janelas deslizantes (`window_size = 30`) são geradas *dentro* de cada partição, nunca cruzando a fronteira treino/teste. O resultado são ≈ 2450 janelas de treino e ≈ 1215 de teste por ativo, no formato $(n, 30, 1)$.

6.3 Revisão da hipótese sobre o AMER3

Em M1, levantou-se a hipótese de que o salto de log-retorno de $\approx +1,03$ em 14/11/2024 seria um *artefato* de grupamento, e decidiu-se, provisoriamente, “corrigir o fator”. A investigação conduzida em M2 **refutou essa hipótese** e ilustra a importância de validar premissas com os dados:

- Os grupamentos reais do AMER3 ocorreram em **julho e agosto de 2024** (quatro eventos de razão 1:100 registrados pela fonte) e **já são corrigidos por `auto_adjust=True`**: o log-retorno ajustado nessas datas é pequeno ($+0,09$; $+0,01$; $-0,18$; $+0,34$), com série contínua.
- Em 14/11/2024 o preço bruto saltou de R\$ 3,36 para R\$ 9,41 com volume cerca de três vezes a média e *sem split* registrado — caracterizando um **movimento de mercado real** (especulação durante a recuperação judicial), assim como o salto de 15/08/2024.
- Como o log-retorno é invariante a escala, *splits* já aplicados não produzem retorno espúrio.

Decisão revista: nenhuma correção é aplicada; o AMER3 segue o mesmo pipeline dos demais ativos, e seus saltos de 2024 são tratados como anomalias reais (verdade narrativa para M6). O registro completo está no ADR-0007.

7 M3 — Modelo e Treino

7.1 Arquitetura

Implementou-se o LSTM-Autoencoder descrito na Seção 3: um codificador LSTM(64) seguido de *dropout* e de uma camada densa de gargalo (`latent_dim=16`); o decodificador replica o vetor latente (`RepeatVector`) e o reconstrói com LSTM(64) e `TimeDistributed(Dense(1))`. A rede tem $\approx 38,7$ mil parâmetros — deliberadamente pequena, coerente com o tamanho do conjunto (≈ 2450 janelas por ativo). A perda é o MSE de reconstrução e o otimizador é o Adam.

7.2 Protocolo de treino

Treinou-se **um modelo por ativo**, com validação por bloco cronológico (`shuffle=False`) e `EarlyStopping` (paciência 10, `restore_best_weights`). Os pesos são salvos em `models/<ticker>.keras` (regeneráveis, não versionados). A Tabela 4 resume a convergência: a parada antecipada atuou em todos os casos, com perdas de validação da mesma ordem de grandeza entre ativos e sem sinais de sobreajuste nas curvas.

Tabela 4: Convergência do treino por ativo (`EarlyStopping`).

Ticker	Épocas até parar	val_loss final
PETR4.SA	31	0,00352
VALE3.SA	15	0,00430
AMER3.SA	60	0,00354
ITUB4.SA	17	0,00440

7.3 Sensibilidade do gargalo

A dimensão latente havia sido fixada como decisão de projeto, a calibrar nesta etapa. Um estudo em PETR4 com `latent_dim` $\in \{8, 16, 32\}$ produziu `val_loss` praticamente idêntico (0,00342; 0,00343; 0,00342). Conclui-se que, neste regime, o gargalo **não é restrição ativa** — o modelo reconstrói os log-retornos igualmente bem nas três configurações. Mantém-se `latent_dim=16`, agora confirmado empiricamente (registro no ADR-0003).

7.4 Baseline de comparação

Como chão de comparação sem aprendizado (issue #14), implementou-se um *z-score* em janela móvel causal sobre os log-retornos. O baseline acende corretamente nas anomalias reais — por exemplo, no AMER3, $|z| = 13,9$ em 12/01/2023 (fraude) e $|z| = 9,7$ em 14/11/2024. Trata-se de um detector forte para eventos extremos; o valor agregado do LSTM-Autoencoder será medido quantitativamente em M5, por injeção de anomalias sintéticas mais sutis, onde se espera que heurísticas de cauda sejam menos eficazes.

7.5 Erro de reconstrução

Sobre o conjunto de treino (normalidade), o erro de reconstrução (MAE por janela) concentra-se em valores baixos, com cauda à direita já indicando candidatos a anomalia. Essa distribuição é a base para a definição formal dos limiares em M4.

8 M4 — Detecção e Limiares

8.1 Erro de reconstrução

A detecção opera sobre o erro de reconstrução por janela — o erro médio absoluto (MAE) entre a janela de entrada e sua reconstrução. Optou-se pelo MAE por sua maior robustez a *outliers* isolados em relação ao MSE (este último disponível como opção). Uma janela é classificada como anômala quando seu erro supera o limiar.

8.2 Limiar estático

O limiar estático é o percentil 95 do erro de reconstrução *do treino*. Por ser calculado sobre o período de normalidade (e não sobre o teste), não incorre em vazamento. É simples e estável,

mas, por definição, fixo: não se adapta a mudanças no regime de volatilidade do ativo.

8.3 Limiar dinâmico

O limiar dinâmico é o percentil 95 calculado em uma janela móvel **causal** de `dynamic_window = 252` observações (≈ 1 ano útil). A causalidade é garantida excluindo-se o próprio ponto da janela (deslocamento de uma posição), de modo que uma anomalia não infle o limiar que a avalia; os primeiros pontos, com janela incompleta, não são marcados. Esse esquema constitui uma das contribuições metodológicas do trabalho.

8.4 Comparação empírica

A Tabela 5 compara, no conjunto de teste (2020–2024), a fração de janelas marcadas por cada esquema. O resultado evidencia o comportamento esperado:

- Em ativos de regime relativamente estável (PETR4, VALE3), os dois limiares quase coincidem ($\approx 3\%$).
- Sob mudança abrupta de regime, o limiar estático **satura**: no AMER3, todo o período pós-fraude/recuperação judicial faz o erro permanecer elevado, e o estático marca $\approx 27\%$ das janelas — perdendo poder discriminativo. O limiar dinâmico, ao se recalibrar à volatilidade local, reduz a marcação para $\approx 14\%$ sem usar informação do futuro. Comportamento análogo no ITUB4 ($11\% \rightarrow 5\%$).

Tabela 5: Fração de janelas de teste marcadas como anômalas, por limiar.

Ticker	Limiar estático	Estático (%)	Dinâmico (%)
PETR4.SA	0,124	2,9	2,9
VALE3.SA	0,082	2,7	3,4
AMER3.SA	0,077	26,7	14,3
ITUB4.SA	0,088	11,0	4,9

Observações metodológicas. O percentil 95 implica, por construção, uma taxa-base de $\approx 5\%$ de marcações — a considerar na leitura das métricas (M5). Além disso, como as janelas se sobrepõem, uma única anomalia gera uma rajada de detecções contíguas; antes de confrontar com eventos reais (M6) ou calcular métricas (M5), detecções adjacentes devem ser agrupadas em “eventos”.

8.5 Sensibilidade da janela dinâmica

O tamanho `dynamic_window` era provisório; a Tabela 6 fecha a questão variando-o em $\{126, 252, 504\}$. O comportamento é monotônico: a janela curta (126) é reativa — segue o ruído local e infla a marcação ($\approx 8\%$ nos ativos estáveis), enquanto a janela longa (504) super-suaviza, aproximando-se de um limiar global e colapsando a marcação a $\approx 0\%$ — perdendo a capacidade de sinalizar. O valor intermediário **252** produz taxas próximas da base-rate alvo ($\approx 5\%$ do p95) sem oscilar nem colapsar, e é confirmado como escolha definitiva (ADR-0005).

9 M5 — Avaliação Quantitativa por Injeção Sintética

9.1 Motivação e desenho

O problema é não supervisionado: não há rótulos de anomalia reais. Para obter métricas quantitativas (*Precision*, *Recall*, F1) injetam-se anomalias em posições *conhecidas* da série de




Figura 1: Erro de reconstrução no teste (2020–2024) com limiar estático (p95, tracejado vermelho) e dinâmico (verde). O dinâmico acompanha o regime de volatilidade; no AMER3 o estático satura no período pós-fraude.

Tabela 6: Fração de janelas de teste marcadas pelo limiar dinâmico, por tamanho de janela.

Ticker	126	252	504
PETR4.SA	8,5%	2,9%	0,0%
VALE3.SA	8,2%	3,4%	0,3%
AMER3.SA	15,2%	14,3%	5,7%
ITUB4.SA	6,3%	4,9%	0,0%

teste, produzindo um *ground-truth* controlado (ADR-0006). Foram inseridos $n = 50$ *price shocks* por ativo, em posições aleatórias (*seed* fixa), somando um delta de magnitude `price_shock` = 0,15 ao log-retorno **já escalado** — o mesmo espaço em que o modelo foi treinado. Injetar no preço bruto produziria choques de magnitude variável conforme o nível de preço do ativo.

9.2 Regra de rotulagem por janela

Como o modelo processa janelas de 30 passos, um choque em qualquer posição eleva o erro de reconstrução de toda a janela. Adota-se, portanto, a regra: uma janela é positiva se **qualquer** passo injetado cair dentro dela. Os vetores de rótulo e de *flags* do detector ficam alinhados janela a janela, seguindo a mesma indexação de `make_windows` (Seção 6), o que evita desalinhamento temporal no cálculo das métricas.

9.3 Resultados

A Tabela 7 apresenta as métricas por ativo, comparando limiar estático (p95 do treino) e dinâmico (calculado sobre os erros da série perturbada). O padrão é claro e metodologicamente informativo:

- O *recall* é **uniformemente baixo** nos ativos de regime estável (PETR4, VALE3: *recall* < 7%). Com magnitude *absoluta* de 0,15 no espaço escalado, o choque sintético é comparável

ao ruído normal desses ativos e raramente empurra a janela acima do limiar.

- Onde o regime de erro de base é mais alto (AMER3, ITUB4), os choques são detectados com mais frequência (AMER3 estático: recall $\approx 30\%$, F1 $\approx 0,42$).
- O limiar dinâmico tende a elevar a *precision* (ex. VALE3 e ITUB4 acima de 0,9), por se ajustar ao ruído local, mas sem ganho de *recall*.

Tabela 7: Precision / Recall / F1 do detector contra o *ground-truth* sintético ($n = 50$ price shocks, price_shock= 0,15).

Ticker	Limiar	Precision	Recall	F1
PETR4.SA	estático	0,139	0,006	0,011
PETR4.SA	dinâmico	0,548	0,020	0,038
VALE3.SA	estático	0,111	0,005	0,009
VALE3.SA	dinâmico	0,964	0,061	0,115
AMER3.SA	estático	0,694	0,303	0,421
AMER3.SA	dinâmico	0,605	0,120	0,200
ITUB4.SA	estático	0,769	0,130	0,222
ITUB4.SA	dinâmico	0,939	0,036	0,069




Figura 2: Distribuição do erro de reconstrução (MAE) de treino e teste, com o limiar p95 (traçado). A cauda direita da distribuição de teste além do limiar concentra as janelas candidatas a anomalia; o deslocamento treino $\rightarrow$ teste é mais acentuado no AMER3.

9.4 Leitura crítica

O *recall* baixo **não** indica falha do detector, mas que a magnitude de injeção é **provisória e absoluta**: a dificuldade da tarefa varia arbitrariamente entre ativos, penalizando os de baixa volatilidade. Esta é a evidência empírica que motiva a recomendação do ADR-0006: calibrar o choque em k desvios-padrão do retorno *de cada ativo*, tornando a dificuldade comparável entre setores. A avaliação corrente, portanto, é um piso metodológico — valida o *pipeline* de métricas

(injeção $\rightarrow$ rotulagem $\rightarrow$ P/R/F1), e não um resultado final. Adicionalmente, a taxa-base de $\approx 5\%$ imposta pelo p95 (Seção 8) limita a *precision* máxima atingível e deve ser lida em conjunto.

9.5 Calibração relativa $k\sigma$

Atendendo à recomendação do ADR-0006, a injeção foi reimplementada com magnitude **relativa**: $\text{mag} = k\sigma$, com σ igual ao desvio-padrão dos retornos escalados de treino (normalidade) de cada ativo e $k = 4$ (um choque de quatro desvios-padrão). Assim “um choque de 4σ ” tem o mesmo significado estatístico em todos os ativos. A Tabela 8 traz as métricas resultantes (limiar estático).

Tabela 8: Métricas com choque relativo de 4σ por ativo (limiar estático).

Ticker	mag (4σ)	Precision	Recall	F1
PETR4.SA	0,345	0,205	0,009	0,018
VALE3.SA	0,246	0,396	0,024	0,046
AMER3.SA	0,273	0,763	0,429	0,549
ITUB4.SA	0,312	0,826	0,185	0,303

A calibração melhora as métricas onde já havia sinal (AMER3 F1 $0,42 \rightarrow 0,55$), mas o resultado central é negativo e instrutivo: **a magnitude não equaliza a dificuldade entre ativos**. Mesmo a 4σ — e em testes a 6σ — o *recall* dos ativos estáveis permanece baixo. A restrição dominante não é o tamanho do choque, mas (i) a altura do limiar p95 relativa ao regime de erro de cada ativo e (ii) a **diluição por janela**: um choque de um único passo entra no MAE *médio* de uma janela de 30 passos, contribuindo cerca de $1/30$ do erro. Aumentar a sensibilidade exigiria choques multi-passo, um erro por *máximo* na janela (em vez de média) ou um limiar por ativo mais agressivo — registrado como trabalho futuro.

Volume spikes. A injeção de *volume spikes* (chave `volume_spike`) **não é aplicável** à arquitetura atual: o modelo é univariado (entrada = log-retornos de `Close`), de modo que uma perturbação de volume não altera o erro de reconstrução. Avaliá-la exigiria um autoencoder multivariado (OHLCV), o que reabriria M3/M4; fica registrada como trabalho futuro (ADR-0006).

10 M6 — Correlação com Eventos e Comparação Setorial

10.1 Validação narrativa

Complementando a avaliação quantitativa (Seção 9), as anomalias detectadas no teste (limiar estático p95) são cruzadas com uma linha do tempo curada de eventos econômicos e políticos brasileiros de 2010–2024 (`src/events.py`; ADR-0008). Cada evento é classificado como *sistêmico* (afeta todos os ativos) ou *específico* de um *ticker*. Considera-se um evento “coberto” quando há ao menos uma anomalia dentro de uma tolerância de $\pm \text{window_size}$ (± 30 dias), justificada pelo fato de a unidade de detecção ser a janela de 30 passos.

A cobertura narrativa global é de $\approx 50\%$, mas o número agregado esconde o resultado relevante — o **casamento entre evento e ativo afetado**:

- **AMER3** cobre 9 de 10 eventos a ela associados, incluindo a fraude contábil (jan/2023) e a recuperação judicial — o sinal mais forte do *dataset*.
- PETR4, VALE3 e ITUB4 cobrem cerca de 2 eventos cada (de 6–8): seus modelos disparam sobretudo em eventos *sistêmicos* e nos choques setoriais de maior magnitude, permane-

cendo silenciosos em eventos de impacto difuso — coerente com um detector calibrado para a cauda do erro (p95).




Figura 3: AMER3 (2022–2024): erro de reconstrução, janelas anômalas (pontos vermelhos) e eventos (linhas pontilhadas). O pico de erro de jan/2023 coincide com a fraude contábil e o pedido de recuperação judicial.

10.2 Comparação setorial

Com um modelo por ativo, comparam-se as taxas de marcação entre setores (Tabela 9). As taxas reproduzem o achado da M4: PETR4 (energia) e VALE3 (mineração) são estáveis ($\approx 3\%$), enquanto AMER3 (varejo) exibe regime de volatilidade prolongada (26,7% no estático, recalibrado para 14,3% no dinâmico) e ITUB4 (financeiro) fica em posição intermediária. A diferença reflete o *ativo*, não necessariamente o *setor* ($n = 1$ por setor): trata-se de estudo de caso qualitativo, não de inferência estatística (ADR-0006).

Tabela 9: Taxa de janelas anômalas no teste (2020–2024) por ativo/setor.

Ticker	Setor	Limiar p95	Estático (%)	Dinâmico (%)
PETR4.SA	Energia/commodities	0,124	2,9	2,9
VALE3.SA	Mineração	0,082	2,7	3,4
AMER3.SA	Varejo	0,077	26,7	14,3
ITUB4.SA	Financeiro	0,088	11,0	4,9

10.3 Contágio sistêmico: o teste da COVID

Um evento sistêmico deve aparecer em *todos* os ativos. No *crash* da COVID (fev–mai/2020), os quatro modelos sinalizam anomalia de forma concentrada no período (PETR4: 35; VALE3: 33; ITUB4: 54; AMER3: 56 janelas), confirmando o contágio entre setores. Em contraste, eventos setor-específicos — Brumadinho ($\rightarrow$ VALE3), fraude Americanas ($\rightarrow$ AMER3), intervenção na Petrobras ($\rightarrow$ PETR4) — isolam-se nos ativos afetados. A combinação dos dois comportamentos evidencia que os modelos, treinados por ativo, captam tanto choques de mercado amplos quanto eventos idiossincráticos — o objetivo de generalização cruzada declarado na proposta.

Limitações em aberto. O estudo de sensibilidade da janela dinâmica ($\text{dynamic_window} \in \{126, 252, 504\}$) previsto no ADR-0005 e a calibração das magnitudes de injeção relativas a σ (ADR-0006) permanecem pendentes e são os próximos refinamentos antes do fechamento do artigo.




Figura 4: *Crash* da COVID (fev–mai/2020): os quatro ativos, de setores distintos, sinalizam anomalias concentradas no mesmo período, confirmando o contágio sistêmico.

11 Limitações e Validade

11.1 O período de treino “normal” não é livre de anomalias

A premissa central do método é que o autoencoder aprende a “normalidade” a partir de 2010–2019 e sinaliza como anômalo o que dele se desvia no teste (2020–2024). Essa premissa é, contudo, uma **idealização**: o próprio período de treino contém episódios de alta volatilidade — a recessão de 2014–2016, a Operação Lava Jato e seus desdobramentos sobre a Petrobras, e o *impeachment* de 2016. “Normal”, aqui, significa apenas *relativo ao que o modelo viu*, não um regime efetivamente calmo. Há duas consequências diretas:

- O modelo **incorpora** parte dessa turbulência como padrão esperado, elevando o limiar de normalidade e reduzindo sua sensibilidade a choques de magnitude semelhante no teste — um viés conservador (tende a subestimar anomalias).
- A comparação treino vs. teste do erro (Figura 2) deve ser lida à luz disso: parte do deslocamento de distribuição reflete diferença de regime macro entre as duas janelas temporais, não apenas anomalias pontuais.

Optou-se deliberadamente por *não* remover esses episódios do treino: fazê-lo exigiria rótulos de anomalia que o problema não-supervisionado não possui, e introduziria subjetividade. A limitação é, portanto, assumida e reportada, não corrigida.

11.2 Demais limitações

- **Avaliação setorial com $n = 1$** : um único ativo por setor; diferenças de métrica podem refletir o ativo, não o setor. Estudo de caso qualitativo, não inferência estatística (ADR-0006).
- **Modelo univariado**: a entrada é o log-retorno de `Close`; volume e demais colunas OHLCV não são usados. Anomalias puramente de volume são, por construção, invisíveis (Seção 9.5).
- **Diluição por janela**: o erro é a média sobre 30 passos, de modo que um choque de um único dia é atenuado, limitando o *recall* a choques pontuais.

- **Taxa-base do p95:** por construção, $\approx 5\%$ das janelas são marcadas, impondo um teto à *precision* (Seção 8).
- **Avaliação por injeção sintética:** a verdade-base é controlada, porém artificial; complementa, mas não substitui, a validação narrativa contra eventos reais.

12 Reprodutibilidade e Entrega

O pipeline é integralmente reprodutível e offline:

- **Semente única** (`seed=42`) fixada em `src.config.set_seeds`, cobrindo `numpy`, `random` e `TensorFlow`.
- **Configuração centralizada:** todos os hiperparâmetros vivem em `config.yaml`, cada chave referenciando seu ADR; experimentos mudam por edição de configuração, não de código.
- **Dados versionados:** os CSVs de `data/raw/` são commitados, de modo que o pipeline roda sem acesso à rede; o `yfinance` só é necessário para refazer o *cache* do zero.
- **Ordem de execução:** notebooks numerados `01_eda` $\rightarrow$ `02_preprocessing` $\rightarrow$ `03_train` $\rightarrow$ `04_detection_thresholds` $\rightarrow$ `05_evaluation_synthetic` $\rightarrow$ `06_events_correlation`, todos consumindo a lógica de `src/`.
- **Decisões rastreáveis:** oito ADRs em `docs/adr/` registram cada escolha metodológica, com proveniência (FUNDAMENTADO / DEFAULT DE LITERATURA / DECISÃO DE PROJETO / PROVISÓRIO).

Os números deste relatório foram regenerados a partir dos modelos treinados (`models/*.keras`) e conferem com as tabelas e figuras apresentadas. As figuras finais são geradas em `report/figures/` e versionadas para que o PDF compile de forma auto-contida. Observação operacional: em um clone novo, os notebooks (com saídas removidas por `nbstripout`) exigem reinstalar o filtro local antes de versioná-los; a regeneração de resultados não depende disso.

13 Conclusões Parciais e Próximos Passos

Até este ponto, o projeto estabeleceu uma base reprodutível (M0), validou a qualidade dos dados (M1), construiu a representação de entrada (M2), treinou os modelos (M3), formalizou os limiares de detecção (M4), avaliou-os quantitativamente por injeção sintética (M5) e cruzou as detecções com eventos reais e setores (M6). Os principais resultados parciais são:

- Infraestrutura com configuração centralizada, *seeds* fixas e proveniência documentada de cada hiperparâmetro, separando escolhas fundamentadas de valores provisórios.
- Quatro séries íntegras (3724 pregões, sem NaN), com anomalias reais já mapeadas como âncoras para a validação narrativa.
- Esclarecimento do caso AMER3: a hipótese de artefato de agrupamento foi refutada com os dados, e o ativo segue o pipeline padrão (Seção 6.3).
- Representação de entrada pronta: log-retornos normalizados em janelas de 30 passos, com split temporal e scaler restrito ao treino (sem vazamento).
- Quatro modelos treinados com parada antecipada e `val_loss` homogêneo; a sensibilidade do gargalo (`latent_dim`) mostrou-se plana, confirmando o valor 16 (Seção 7).
- Limiares de detecção implementados: sob mudança de regime, o estático satura (AMER3 $\approx 27\%$) enquanto o dinâmico causal se recalibra ($\approx 14\%$), evidência empírica a favor do esquema dinâmico (Seção 8).
- *Pipeline* de avaliação quantitativa pronto: injeção sintética $\rightarrow$ rotulagem por janela $\rightarrow$ Precision/Recall/F1 (Seção 9). A magnitude absoluta provisória (0,15) produz *recall* baixo em ativos estáveis, evidenciando empiricamente a necessidade de calibrar o choque em $k\sigma$ por ativo.

- Validação narrativa e setorial (Seção 10): eventos sistêmicos (COVID) dispararam em todos os ativos e eventos idiossincráticos isolam-se no ativo afetado (AMER3 cobre 9/10 de seus eventos), confirmando a generalização cruzada por ativo.

Refinamentos da M7. Três pendências metodológicas foram fechadas: (i) o estudo de sensibilidade da janela dinâmica confirmou `dynamic_window=252` (126 é ruidoso, 504 colapsa a marcação — Seção 8.5); (ii) a injeção foi recalibrada para magnitude relativa $k\sigma$ por ativo, revelando que a detectabilidade é limitada pela diluição do choque na janela e pelo regime de erro do ativo, não pela magnitude (Seção 9.5); (iii) a injeção de *volume spikes* foi caracterizada como fora do escopo da arquitetura univariada atual.

Próximos passos. Consolidar as evidências no artigo final e, como trabalho futuro, avaliar um autoencoder multivariado (OHLVCV) que viabilize *volume spikes* e um erro de reconstrução por máximo na janela, ambos para aumentar a sensibilidade a choques pontuais.

Registro de decisões. Todas as decisões de configuração estão documentadas como ADRs em `docs/adr/`. Este relatório é atualizado a cada fechamento de *milestone*, consolidando decisões, fontes, observações e conclusões para compor o artigo final.

Referências

- [1] Martín Abadi et al. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. <https://www.tensorflow.org/>.
- [2] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [3] IEEE. Anomaly detection on Bitcoin values. In *Proceedings of the IEEE*, 2021.
- [4] Susan Li. Time series of price anomaly detection with LSTM. Towards Data Science, 2020. <https://medium.com/data-science/time-series-of-price-anomaly-detection-with-lstm-11a12ba4f6d9>.
- [5] Yifan Liu et al. Robust anomaly detection in financial markets using LSTM autoencoders and generative adversarial networks. *Journal of Economics, Finance and Accounting Studies*, 2025. OPAST Publishers.
- [6] Dejan Petrovic. Anomaly detection in stock price with LSTM autoencoder. GitHub, 2019. <https://github.com/dpetrovic89/Anomaly-Detection-in-Stock-Price-with-LSTM-Autoencoder>.
- [7] Venelin Valkov. Time series anomaly detection with LSTM autoencoders using Keras in Python. *curiously.com*, 2019. <https://curiously.com/posts/anomaly-detection-in-time-series-with-lstms-using-keras-in-python/>.