

# Detecção Não Supervisionada de Anomalias em Séries Temporais Financeiras Brasileiras com LSTM-Autoencoder

Relatório Preliminar

Ana Beatriz and Miguel Cerne

Redes Neurais (2026.1)

23 de junho de 2026

## Resumo

A detecção de anomalias em mercados financeiros é dominada, na literatura, pelo mercado norte-americano e por criptomoedas. Este trabalho aplica uma arquitetura *LSTM-Autoencoder* à detecção não supervisionada de anomalias em quatro ações da B3 (PETR4, VALE3, AMER3 e ITUB4), cobrindo distintos setores econômicos. O modelo é treinado apenas sobre o período considerado de “normalidade” (2010–2019) e sinaliza como anômalas as janelas cujo erro de reconstrução excede um limiar; comparam-se limiares estático (percentil fixo) e dinâmico (percentil em janela móvel causal). A avaliação combina validação narrativa (sobreposição com eventos econômicos e políticos brasileiros documentados) e quantitativa (injeção controlada de anomalias sintéticas, com Precision, Recall e F1). Este relatório preliminar documenta, de forma incremental e academicamente rastreável, as decisões metodológicas, suas fontes e as observações de cada etapa do projeto. Até o momento concluíram-se as etapas de *infraestrutura* (M0) e de *coleta e análise exploratória* (M1).

**Palavras-chave:** detecção de anomalias; LSTM-Autoencoder; séries temporais financeiras; B3; aprendizado não supervisionado.

## Sumário

|          |                                                |          |
|----------|------------------------------------------------|----------|
| <b>1</b> | <b>Introdução</b>                              | <b>2</b> |
| 1.1      | Contribuições                                  | 3        |
| 1.2      | Ativos e período                               | 3        |
| 1.3      | Sobre este documento                           | 3        |
| <b>2</b> | <b>Trabalhos Relacionados</b>                  | <b>3</b> |
| <b>3</b> | <b>Metodologia</b>                             | <b>4</b> |
| 3.1      | Pré-processamento                              | 4        |
| 3.2      | Modelo                                         | 4        |
| 3.3      | Detecção                                       | 4        |
| 3.4      | Avaliação                                      | 4        |
| <b>4</b> | <b>M0 — Infraestrutura e Reprodutibilidade</b> | <b>4</b> |
| 4.1      | Ambiente e dependências                        | 4        |
| 4.2      | Configuração centralizada e seeds              | 5        |
| 4.3      | Decisões de hiperparâmetros e proveniência     | 5        |
| 4.4      | Riscos metodológicos registrados               | 5        |

|           |                                                          |           |
|-----------|----------------------------------------------------------|-----------|
| <b>5</b>  | <b>M1 — Coleta e Análise Exploratória</b>                | <b>5</b>  |
| 5.1       | Coleta e cache . . . . .                                 | 5         |
| 5.2       | Integridade das séries . . . . .                         | 6         |
| 5.3       | Anomalias reais identificadas . . . . .                  | 6         |
| 5.4       | O caso AMER3 . . . . .                                   | 6         |
| <b>6</b>  | <b>M2 — Pré-processamento</b>                            | <b>6</b>  |
| 6.1       | Log-retornos . . . . .                                   | 7         |
| 6.2       | Split temporal e normalização . . . . .                  | 7         |
| 6.3       | Revisão da hipótese sobre o AMER3 . . . . .              | 7         |
| <b>7</b>  | <b>M3 — Modelo e Treino</b>                              | <b>7</b>  |
| 7.1       | Arquitetura . . . . .                                    | 7         |
| 7.2       | Protocolo de treino . . . . .                            | 7         |
| 7.3       | Sensibilidade do gargalo . . . . .                       | 8         |
| 7.4       | Baseline de comparação . . . . .                         | 8         |
| 7.5       | Erro de reconstrução . . . . .                           | 8         |
| <b>8</b>  | <b>M4 — Detecção e Limiares</b>                          | <b>8</b>  |
| 8.1       | Erro de reconstrução . . . . .                           | 8         |
| 8.2       | Limiar estático . . . . .                                | 8         |
| 8.3       | Limiar dinâmico . . . . .                                | 8         |
| 8.4       | Comparação empírica . . . . .                            | 9         |
| <b>9</b>  | <b>M5 — Avaliação Quantitativa por Injeção Sintética</b> | <b>9</b>  |
| 9.1       | Motivação e desenho . . . . .                            | 9         |
| 9.2       | Regra de rotulagem por janela . . . . .                  | 9         |
| 9.3       | Resultados . . . . .                                     | 10        |
| 9.4       | Leitura crítica . . . . .                                | 10        |
| <b>10</b> | <b>M6 — Correlação com Eventos e Comparação Setorial</b> | <b>10</b> |
| 10.1      | Validação narrativa . . . . .                            | 10        |
| 10.2      | Comparação setorial . . . . .                            | 11        |
| 10.3      | Contágio sistêmico: o teste da COVID . . . . .           | 11        |
| <b>11</b> | <b>Conclusões Parciais e Próximos Passos</b>             | <b>11</b> |

## 1 Introdução

A identificação de comportamentos atípicos em séries de preços de ativos é relevante tanto para a gestão de risco quanto para a compreensão de como eventos econômicos e políticos se refletem nos mercados. A maior parte da literatura de detecção de anomalias com aprendizado profundo concentra-se no mercado norte-americano e em criptomoedas [3, 4], deixando sub-representado o contexto de mercados emergentes como o brasileiro.

Este trabalho investiga a detecção *não supervisionada* de anomalias em ações da B3 por meio de um *LSTM-Autoencoder* [2]. A premissa é que um autoencoder treinado apenas em períodos de comportamento típico aprende a reconstruir os padrões normais da série; diante de movimentos atípicos, o erro de reconstrução cresce e sinaliza a anomalia.

## 1.1 Contribuições

O projeto combina quatro contribuições:

1. Aplicação a ativos nacionais (B3), contexto sub-representado na literatura.
2. Correlação sistemática e documentada entre anomalias detectadas e eventos históricos brasileiros.
3. Comparação entre limiar *estático* (percentil fixo) e *dinâmico* (percentil em janela móvel).
4. Avaliação de generalização entre setores econômicos distintos.

## 1.2 Ativos e período

Foram selecionados quatro ativos, um por setor, conforme a Tabela 1. O período de coleta vai de 2010 a 2024; o treino (“normalidade”) usa 2010–2019 e o teste, 2020–2024.

Tabela 1: Ativos analisados.

| Ticker   | Empresa         | Setor               |
|----------|-----------------|---------------------|
| PETR4.SA | Petrobras PN    | Energia/commodities |
| VALE3.SA | Vale S.A.       | Mineração           |
| AMER3.SA | Americanas S.A. | Varejo              |
| ITUB4.SA | Itaú Unibanco   | Financeiro          |

## 1.3 Sobre este documento

Trata-se de um relatório preliminar e *vivo*: a cada fechamento de *milestone* acrescenta-se uma seção descrevendo, academicamente, as decisões tomadas, suas fontes, as observações empíricas e as conclusões parciais. As decisões de configuração são registradas em paralelo como *Architecture Decision Records* (ADRs) no repositório (`docs/adr/`), referenciados ao longo do texto.

## 2 Trabalhos Relacionados

A detecção de anomalias com autoencoders recorrentes baseia-se na ideia de que a reconstrução de padrões aprendidos falha sobre observações fora da distribuição de treino. Li [4], em referência amplamente reproduzida, aplica um LSTM-Autoencoder a preços de ações (Johnson & Johnson), adotando janelas de 30 passos de tempo e definindo o limiar de anomalia a partir do erro de reconstrução do treino. Valkov [7] fornece uma implementação canônica em Keras, com escolhas de projeto que servem de referência prática (camadas LSTM de 64 unidades, *dropout* de 0,2, *validation\_split* de 0,1 e, crucialmente, *shuffle=False* para preservar a ordem temporal). Petrovic [6] disponibiliza um repositório com abordagem equivalente.

Trabalhos mais recentes ampliam o desenho experimental. Liu et al. [5] propõem um arcabouço híbrido que acopla um LSTM-Autoencoder a redes adversárias generativas e introduzem explicitamente um *mecanismo de injeção artificial de anomalias* para avaliação quantitativa, validado em múltiplas categorias de ações — desenho que inspira diretamente a avaliação setorial e por injeção adotada neste projeto. No domínio de criptomoedas, IEEE [3] exploram a mesma família de modelos sobre valores do Bitcoin.

Em relação a esses trabalhos, a principal lacuna endereçada aqui é a aplicação ao mercado brasileiro (B3) com correlação documentada a eventos nacionais e comparação explícita entre estratégias de limiar estático e dinâmico.

## 3 Metodologia

Esta seção descreve o desenho metodológico do projeto. Os valores numéricos de hiperparâmetros e suas justificativas são apresentados nas seções de cada *milestone* e consolidados nos ADRs do repositório.

### 3.1 Pré-processamento

A feature principal é o *retorno logarítmico diário*,  $r_t = \ln(P_t/P_{t-1})$ , sobre o preço de fechamento ajustado. Adota-se um **split temporal antes da normalização**: o `MinMaxScaler` é ajustado *apenas* sobre o treino e então aplicado ao teste, evitando vazamento de informação do futuro. A série é então segmentada em *janelas deslizantes* de tamanho fixo (ver Seção 5).

### 3.2 Modelo

A arquitetura é um *LSTM-Autoencoder* [2]: um codificador LSTM comprime a janela em uma representação latente (gargalo), e um decodificador LSTM reconstrói a sequência, otimizando o erro quadrático médio (MSE) de reconstrução. Treina-se **um modelo por ativo**, condição necessária para a comparação setorial.

### 3.3 Detecção

Uma janela é marcada como anômala quando seu erro de reconstrução ultrapassa um limiar. Comparam-se duas estratégias:

- **Estático:** percentil fixo (95) do erro de reconstrução do treino.
- **Dinâmico:** percentil em janela móvel *causal* (apenas o passado), sensível a mudanças de regime.

### 3.4 Avaliação

Por ser um problema não supervisionado, a avaliação combina duas vias [5]:

- **Narrativa:** verificação de que as anomalias detectadas correspondem a eventos reais conhecidos (e.g., *crash* de março/2020; caso Americanas em janeiro/2023).
- **Quantitativa:** injeção controlada de anomalias sintéticas (*price shocks* e *volume spikes*) em posições conhecidas, permitindo calcular Precision, Recall e F1.

**Nota metodológica.** O período de treino (2010–2019) contém eventos de forte volatilidade (recessão de 2014–2016, Operação Lava Jato, *impeachment* de 2016). A definição de “normalidade” é, portanto, relativa, e essa limitação é assumida explicitamente.

## 4 M0 — Infraestrutura e Reprodutibilidade

A primeira etapa estabeleceu a infraestrutura que garante reprodutibilidade e separação entre lógica e orquestração: a lógica reside em `src/` e os notebooks apenas orquestram e visualizam.

### 4.1 Ambiente e dependências

Fixou-se o interpretador em **Python 3.12.13** (via `pyenv`), versão idêntica à do Google Colab à época, alvo principal de execução. As dependências foram *pinadas* (TensorFlow/Keras [1], `yfinance`, `pandas`, `numpy`, `scikit-learn`, `matplotlib`, `seaborn`), habilitando instalação editável (`pip install -e .`). Notebooks têm suas saídas removidas automaticamente no versionamento (`nbstripout`), reduzindo ruído em *diffs*.

## 4.2 Configuração centralizada e seeds

Todos os hiperparâmetros residem em `config.yaml`, fonte única de verdade: alterar um experimento significa alterar esse arquivo, não os notebooks. O módulo `src/config.py` carrega essa configuração e expõe `set_seeds()`, que fixa as sementes de `random`, `numpy` e `tensorflow` para reprodutibilidade.

## 4.3 Decisões de hiperparâmetros e proveniência

Um princípio metodológico central do projeto é a **rastreabilidade da proveniência** de cada hiperparâmetro. Cada escolha é classificada como: *fundamentada* (ancorada no enunciado do projeto ou na literatura), *default de literatura* (convenção da implementação de referência), *decisão de projeto* (escolha de *design* sem fonte direta, com *rationale* explícito) ou *provisória* (valor a ser calibrado por experimento). A Tabela 2 consolida as principais decisões; os valores provisórios não devem sustentar resultados finais sem validação.

Tabela 2: Principais hiperparâmetros e sua proveniência (consolidado dos ADRs).

| Parâmetro                         | Valor | Proveniência                       |
|-----------------------------------|-------|------------------------------------|
| <code>window_size</code>          | 30    | Fundamentada [4, 7]                |
| <code>lstm_units</code>           | 64    | Default de literatura [7]          |
| <code>dropout</code>              | 0,2   | Default de literatura [7]          |
| <code>latent_dim</code>           | 16    | Decisão de projeto (calibrar)      |
| <code>loss</code>                 | MSE   | Fundamentada [4]                   |
| <code>shuffle</code>              | False | Fundamentada (causalidade) [7]     |
| <code>validation_split</code>     | 0,1   | Default de literatura [7]          |
| <code>threshold_percentile</code> | 95    | Fundamentada (enunciado)           |
| <code>dynamic_window</code>       | 252   | Provisória ( $\approx 1$ ano útil) |
| <code>n_injections</code>         | 50    | Provisória                         |

## 4.4 Riscos metodológicos registrados

Três riscos foram documentados já nesta fase, para serem honrados na implementação: (i) o `validation_split` do Keras separa o *bloco final* dos dados antes de embaralhar — logo `shuffle=False` é obrigatório, sob pena de vazamento temporal; (ii) o limiar dinâmico deve ser *causal*, usando apenas observações passadas; (iii) o `MinMaxScaler` ajustado no treino faz com que extremos do teste possam exceder o intervalo  $[0, 1]$  — comportamento esperado e desejável, pois é onde residem as anomalias, mas que torna o limiar sensível a *outliers* isolados (motivando o uso de percentil em vez do máximo).

# 5 M1 — Coleta e Análise Exploratória

## 5.1 Coleta e cache

Os dados são obtidos via `yfinance` com `auto_adjust=True`, de modo que o preço de fechamento já incorpora ajustes por *splits* e dividendos. A arquitetura de dados separa estritamente o acesso à rede da leitura: as funções `cache_*` baixam e persistem os dados em `data/raw/` (CSV, versionado), enquanto `load_*` — usadas por todo o *pipeline* — leem apenas do cache, jamais da API. Isso garante execução *offline* e reprodutível dos notebooks.

## 5.2 Integridade das séries

As quatro séries apresentam **3724 pregões** cada (2010-01-04 a 2024-12-30), sem valores ausentes (NaN) após o ajuste. A Tabela 3 resume os achados. A função `integrity_report` computa, por ativo, contagens de NaN, dias com volume zero (halts/iliquidez) e os extremos de log-retorno diário, que funcionam como indicadores tanto de anomalias reais quanto de eventuais artefatos.

Tabela 3: Integridade e maior queda diária de log-retorno por ativo.

| Ticker   | Pregões | NaN | Vol. zero | Maior queda (data)  |
|----------|---------|-----|-----------|---------------------|
| PETR4.SA | 3724    | 0   | 54        | −0,352 (2020-03-09) |
| VALE3.SA | 3724    | 0   | 27        | −0,282 (2019-01-28) |
| AMER3.SA | 3724    | 0   | 25        | −1,484 (2023-01-12) |
| ITUB4.SA | 3724    | 0   | 34        | −0,198 (2021-10-04) |

## 5.3 Anomalias reais identificadas

A EDA já revela eventos extremos que servirão de âncora para a validação narrativa (M6):

- **PETR4**, 09/03/2020: queda associada ao início da pandemia de COVID-19 e à guerra de preços do petróleo.
- **VALE3**, 28/01/2019: reação ao rompimento da barragem de Brumadinho.
- **AMER3**, 12/01/2023: divulgação da fraude contábil da Americanas (queda de  $\approx 78\%$  no dia).
- **ITUB4**, 04/10/2021: maior queda do setor financeiro no período.

A distribuição dos log-retornos exhibe caudas pesadas (leptocurtose), o que reforça a escolha de limiares por percentil em vez de critérios baseados em desvio-padrão.

## 5.4 O caso AMER3

A série da Americanas merecia atenção especial por causa da reorganização societária e do colapso pós-fraude. Dois pontos foram esclarecidos pela EDA:

1. **Histórico de treino existe.** Diferentemente da hipótese inicial de ausência de dados em 2010–2019, o `yfinance` fornece a série desde 2010 por continuidade de *ticker* (herdada da Lojas Americanas). Há, portanto, dados de “normalidade” para o ativo.
2. **Sinal vs. artefato.** A queda de 12/01/2023 é uma anomalia *real* e deve ser preservada (é justamente o evento-alvo). Já o salto de log-retorno  $\approx +1,03$  em 14/11/2024 é compatível com um *grupamento* (*reverse split*) não totalmente ajustado pela fonte, configurando provável **artefato**.

Decidiu-se, para a etapa de pré-processamento (M2), **corrigir o fator de grupamento** do AMER3, em vez de recortar o período — preservando a continuidade temporal e o caso completo do ativo.

## 6 M2 — Pré-processamento

Esta etapa transforma as séries de preço na representação consumida pelo modelo, respeitando a ordem metodológica que evita vazamento temporal (Seção 3).

## 6.1 Log-retornos

A feature principal é o retorno logarítmico diário  $r_t = \ln(P_t/P_{t-1})$ , calculado sobre o fechamento ajustado. Por ser invariante a transformações multiplicativas de escala, é imune a fatores de *split*/grupamento já aplicados ao preço — propriedade relevante para o caso AMER3 (Seção 6.3).

## 6.2 Split temporal e normalização

Aplica-se primeiro o *split* temporal (treino até 2019; teste a partir de 2020) e só então a normalização: o `MinMaxScaler` é ajustado *exclusivamente* no treino e aplicado a ambas as partições. Como consequência esperada, uma fração dos pontos de teste extrapola o intervalo  $[0, 1]$  — precisamente os extremos pós-2020 fora da faixa observada no treino. Esse comportamento é desejável: é onde se concentram as anomalias, e o erro de reconstrução tende a crescer ali. As janelas deslizantes (`window_size = 30`) são geradas *dentro* de cada partição, nunca cruzando a fronteira treino/teste. O resultado são  $\approx 2450$  janelas de treino e  $\approx 1215$  de teste por ativo, no formato  $(n, 30, 1)$ .

## 6.3 Revisão da hipótese sobre o AMER3

Em M1, levantou-se a hipótese de que o salto de log-retorno de  $\approx +1,03$  em 14/11/2024 seria um *artefato* de grupamento, e decidiu-se, provisoriamente, “corrigir o fator”. A investigação conduzida em M2 **refutou essa hipótese** e ilustra a importância de validar premissas com os dados:

- Os grupamentos reais do AMER3 ocorreram em **julho e agosto de 2024** (quatro eventos de razão 1:100 registrados pela fonte) e **já são corrigidos por `auto_adjust=True`**: o log-retorno ajustado nessas datas é pequeno ( $+0,09$ ;  $+0,01$ ;  $-0,18$ ;  $+0,34$ ), com série contínua.
- Em 14/11/2024 o preço bruto saltou de R\$ 3,36 para R\$ 9,41 com volume cerca de três vezes a média e *sem split* registrado — caracterizando um **movimento de mercado real** (especulação durante a recuperação judicial), assim como o salto de 15/08/2024.
- Como o log-retorno é invariante a escala, *splits* já aplicados não produzem retorno espúrio.

**Decisão revista:** nenhuma correção é aplicada; o AMER3 segue o mesmo pipeline dos demais ativos, e seus saltos de 2024 são tratados como anomalias reais (verdade narrativa para M6). O registro completo está no ADR-0007.

# 7 M3 — Modelo e Treino

## 7.1 Arquitetura

Implementou-se o LSTM-Autoencoder descrito na Seção 3: um codificador `LSTM(64)` seguido de *dropout* e de uma camada densa de gargalo (`latent_dim=16`); o decodificador replica o vetor latente (`RepeatVector`) e o reconstrói com `LSTM(64)` e `TimeDistributed(Dense(1))`. A rede tem  $\approx 38,7$  mil parâmetros — deliberadamente pequena, coerente com o tamanho do conjunto ( $\approx 2450$  janelas por ativo). A perda é o MSE de reconstrução e o otimizador é o Adam.

## 7.2 Protocolo de treino

Treinou-se **um modelo por ativo**, com validação por bloco cronológico (`shuffle=False`) e `EarlyStopping` (paciência 10, `restore_best_weights`). Os pesos são salvos em `models/<ticker>.keras` (regeneráveis, não versionados). A Tabela 4 resume a convergência: a parada antecipada atuou em todos os casos, com perdas de validação da mesma ordem de grandeza entre ativos e sem sinais de sobreajuste nas curvas.

Tabela 4: Convergência do treino por ativo (EarlyStopping).

| Ticker   | Épocas até parar | val_loss final |
|----------|------------------|----------------|
| PETR4.SA | 31               | 0,00352        |
| VALE3.SA | 15               | 0,00430        |
| AMER3.SA | 60               | 0,00354        |
| ITUB4.SA | 17               | 0,00440        |

### 7.3 Sensibilidade do gargalo

A dimensão latente havia sido fixada como decisão de projeto, a calibrar nesta etapa. Um estudo em PETR4 com `latent_dim`  $\in \{8, 16, 32\}$  produziu `val_loss` praticamente idêntico (0,00342; 0,00343; 0,00342). Conclui-se que, neste regime, o gargalo **não é restrição ativa** — o modelo reconstrói os log-retornos igualmente bem nas três configurações. Mantém-se `latent_dim=16`, agora confirmado empiricamente (registro no ADR-0003).

### 7.4 Baseline de comparação

Como chão de comparação sem aprendizado (issue #14), implementou-se um *z-score* em janela móvel causal sobre os log-retornos. O baseline acende corretamente nas anomalias reais — por exemplo, no AMER3,  $|z| = 13,9$  em 12/01/2023 (fraude) e  $|z| = 9,7$  em 14/11/2024. Trata-se de um detector forte para eventos extremos; o valor agregado do LSTM-Autoencoder será medido quantitativamente em M5, por injeção de anomalias sintéticas mais sutis, onde se espera que heurísticas de cauda sejam menos eficazes.

### 7.5 Erro de reconstrução

Sobre o conjunto de treino (normalidade), o erro de reconstrução (MAE por janela) concentra-se em valores baixos, com cauda à direita já indicando candidatos a anomalia. Essa distribuição é a base para a definição formal dos limiares em M4.

## 8 M4 — Detecção e Limiares

### 8.1 Erro de reconstrução

A detecção opera sobre o erro de reconstrução por janela — o erro médio absoluto (MAE) entre a janela de entrada e sua reconstrução. Optou-se pelo MAE por sua maior robustez a *outliers* isolados em relação ao MSE (este último disponível como opção). Uma janela é classificada como anômala quando seu erro supera o limiar.

### 8.2 Limiar estático

O limiar estático é o percentil 95 do erro de reconstrução *do treino*. Por ser calculado sobre o período de normalidade (e não sobre o teste), não incorre em vazamento. É simples e estável, mas, por definição, fixo: não se adapta a mudanças no regime de volatilidade do ativo.

### 8.3 Limiar dinâmico

O limiar dinâmico é o percentil 95 calculado em uma janela móvel **causal** de `dynamic_window = 252` observações ( $\approx 1$  ano útil). A causalidade é garantida excluindo-se o próprio ponto da janela (deslocamento de uma posição), de modo que uma anomalia não infle o limiar que a avalia; os



primeiros pontos, com janela incompleta, não são marcados. Esse esquema constitui uma das contribuições metodológicas do trabalho.

## 8.4 Comparação empírica

A Tabela 5 compara, no conjunto de teste (2020–2024), a fração de janelas marcadas por cada esquema. O resultado evidencia o comportamento esperado:

- Em ativos de regime relativamente estável (PETR4, VALE3), os dois limiares quase coincidem ( $\approx 3\%$ ).
- Sob mudança abrupta de regime, o limiar estático **satura**: no AMER3, todo o período pós-fraude/recuperação judicial faz o erro permanecer elevado, e o estático marca  $\approx 27\%$  das janelas — perdendo poder discriminativo. O limiar dinâmico, ao se recalibrar à volatilidade local, reduz a marcação para  $\approx 14\%$  sem usar informação do futuro. Comportamento análogo no ITUB4 ( $11\% \rightarrow 5\%$ ).

Tabela 5: Fração de janelas de teste marcadas como anômalas, por limiar.

| Ticker   | Limiar estático | Estático (%) | Dinâmico (%) |
|----------|-----------------|--------------|--------------|
| PETR4.SA | 0,124           | 2,9          | 2,9          |
| VALE3.SA | 0,082           | 2,7          | 3,4          |
| AMER3.SA | 0,077           | 26,7         | 14,3         |
| ITUB4.SA | 0,088           | 11,0         | 4,9          |

**Observações metodológicas.** O percentil 95 implica, por construção, uma taxa-base de  $\approx 5\%$  de marcações — a considerar na leitura das métricas (M5). Além disso, como as janelas se sobrepõem, uma única anomalia gera uma rajada de detecções contíguas; antes de confrontar com eventos reais (M6) ou calcular métricas (M5), detecções adjacentes devem ser agrupadas em “eventos”. O tamanho da janela dinâmica permanece provisório, com estudo de sensibilidade previsto para M5.

## 9 M5 — Avaliação Quantitativa por Injeção Sintética

### 9.1 Motivação e desenho

O problema é não supervisionado: não há rótulos de anomalia reais. Para obter métricas quantitativas (*Precision*, *Recall*, F1) injetam-se anomalias em posições *conhecidas* da série de teste, produzindo um *ground-truth* controlado (ADR-0006). Foram inseridos  $n = 50$  *price shocks* por ativo, em posições aleatórias (*seed* fixa), somando um delta de magnitude `price_shock=0,15` ao log-retorno **já escalado** — o mesmo espaço em que o modelo foi treinado. Injetar no preço bruto produziria choques de magnitude variável conforme o nível de preço do ativo.

### 9.2 Regra de rotulagem por janela

Como o modelo processa janelas de 30 passos, um choque em qualquer posição eleva o erro de reconstrução de toda a janela. Adota-se, portanto, a regra: uma janela é positiva se **qualquer** passo injetado cair dentro dela. Os vetores de rótulo e de *flags* do detector ficam alinhados janela a janela, seguindo a mesma indexação de `make_windows` (Seção 6), o que evita desalinhamento temporal no cálculo das métricas.

### 9.3 Resultados

A Tabela 6 apresenta as métricas por ativo, comparando limiar estático (p95 do treino) e dinâmico (calculado sobre os erros da série perturbada). O padrão é claro e metodologicamente informativo:

- O *recall* é **uniformemente baixo** nos ativos de regime estável (PETR4, VALE3: *recall* < 7%). Com magnitude *absoluta* de 0,15 no espaço escalado, o choque sintético é comparável ao ruído normal desses ativos e raramente empurra a janela acima do limiar.
- Onde o regime de erro de base é mais alto (AMER3, ITUB4), os choques são detectados com mais frequência (AMER3 estático: *recall*  $\approx$ 30%, F1  $\approx$ 0,42).
- O limiar dinâmico tende a elevar a *precision* (ex. VALE3 e ITUB4 acima de 0,9), por se ajustar ao ruído local, mas sem ganho de *recall*.

Tabela 6: Precision / Recall / F1 do detector contra o *ground-truth* sintético ( $n = 50$  *price shocks*, *price\_shock*= 0,15).

| Ticker   | Limiar   | Precision | Recall | F1    |
|----------|----------|-----------|--------|-------|
| PETR4.SA | estático | 0,139     | 0,006  | 0,011 |
| PETR4.SA | dinâmico | 0,548     | 0,020  | 0,038 |
| VALE3.SA | estático | 0,111     | 0,005  | 0,009 |
| VALE3.SA | dinâmico | 0,964     | 0,061  | 0,115 |
| AMER3.SA | estático | 0,694     | 0,303  | 0,421 |
| AMER3.SA | dinâmico | 0,605     | 0,120  | 0,200 |
| ITUB4.SA | estático | 0,769     | 0,130  | 0,222 |
| ITUB4.SA | dinâmico | 0,939     | 0,036  | 0,069 |

### 9.4 Leitura crítica

O *recall* baixo **não** indica falha do detector, mas que a magnitude de injeção é **provisória e absoluta**: a dificuldade da tarefa varia arbitrariamente entre ativos, penalizando os de baixa volatilidade. Esta é a evidência empírica que motiva a recomendação do ADR-0006: calibrar o choque em  $k$  desvios-padrão do retorno *de cada ativo*, tornando a dificuldade comparável entre setores. A avaliação corrente, portanto, é um piso metodológico — valida o *pipeline* de métricas (injeção  $\rightarrow$  rotulagem  $\rightarrow$  P/R/F1), e não um resultado final. Adicionalmente, a taxa-base de  $\approx$ 5% imposta pelo p95 (Seção 8) limita a *precision* máxima atingível e deve ser lida em conjunto. A injeção de *volume spikes* (chave *volume\_spike* no *config.yaml*) permanece prevista mas ainda não implementada nesta etapa.

## 10 M6 — Correlação com Eventos e Comparação Setorial

### 10.1 Validação narrativa

Complementando a avaliação quantitativa (Seção 9), as anomalias detectadas no teste (limiar estático p95) são cruzadas com uma linha do tempo curada de eventos econômicos e políticos brasileiros de 2010–2024 (*src/events.py*; ADR-0008). Cada evento é classificado como *sistêmico* (afeta todos os ativos) ou *específico* de um *ticker*. Considera-se um evento “coberto” quando há ao menos uma anomalia dentro de uma tolerância de  $\pm$ *window\_size* ( $\pm$ 30 dias), justificada pelo fato de a unidade de detecção ser a janela de 30 passos.

A cobertura narrativa global é de  $\approx$ 50%, mas o número agregado esconde o resultado relevante — o **casamento entre evento e ativo afetado**:

- **AMER3** cobre 9 de 10 eventos a ela associados, incluindo a fraude contábil (jan/2023) e a recuperação judicial — o sinal mais forte do *dataset*.
- PETR4, VALE3 e ITUB4 cobrem cerca de 2 eventos cada (de 6–8): seus modelos disparam sobretudo em eventos *sistêmicos* e nos choques setoriais de maior magnitude, permanecendo silenciosos em eventos de impacto difuso — coerente com um detector calibrado para a cauda do erro (p95).

## 10.2 Comparação setorial

Com um modelo por ativo, comparam-se as taxas de marcação entre setores (Tabela 7). As taxas reproduzem o achado da M4: PETR4 (energia) e VALE3 (mineração) são estáveis ( $\approx 3\%$ ), enquanto AMER3 (varejo) exibe regime de volatilidade prolongada (26,7% no estático, recalibrado para 14,3% no dinâmico) e ITUB4 (financeiro) fica em posição intermediária. A diferença reflete o *ativo*, não necessariamente o *setor* ( $n = 1$  por setor): trata-se de estudo de caso qualitativo, não de inferência estatística (ADR-0006).

Tabela 7: Taxa de janelas anômalas no teste (2020–2024) por ativo/setor.

| Ticker   | Setor               | Limiar p95 | Estático (%) | Dinâmico (%) |
|----------|---------------------|------------|--------------|--------------|
| PETR4.SA | Energia/commodities | 0,124      | 2,9          | 2,9          |
| VALE3.SA | Mineração           | 0,082      | 2,7          | 3,4          |
| AMER3.SA | Varejo              | 0,077      | 26,7         | 14,3         |
| ITUB4.SA | Financeiro          | 0,088      | 11,0         | 4,9          |

## 10.3 Contágio sistêmico: o teste da COVID

Um evento sistêmico deve aparecer em *todos* os ativos. No *crash* da COVID (fev–mai/2020), os quatro modelos sinalizam anomalia de forma concentrada no período (PETR4: 35; VALE3: 33; ITUB4: 54; AMER3: 56 janelas), confirmando o contágio entre setores. Em contraste, eventos setor-específicos — Brumadinho ( $\rightarrow$  VALE3), fraude Americanas ( $\rightarrow$  AMER3), intervenção na Petrobras ( $\rightarrow$  PETR4) — isolam-se nos ativos afetados. A combinação dos dois comportamentos evidencia que os modelos, treinados por ativo, captam tanto choques de mercado amplos quanto eventos idiossincráticos — o objetivo de generalização cruzada declarado na proposta.

**Limitações em aberto.** O estudo de sensibilidade da janela dinâmica (`dynamic_window`  $\in \{126, 252, 504\}$ ) previsto no ADR-0005 e a calibração das magnitudes de injeção relativas a  $\sigma$  (ADR-0006) permanecem pendentes e são os próximos refinamentos antes do fechamento do artigo.

## 11 Conclusões Parciais e Próximos Passos

Até este ponto, o projeto estabeleceu uma base reprodutível (M0), validou a qualidade dos dados (M1), construiu a representação de entrada (M2), treinou os modelos (M3), formalizou os limiares de detecção (M4), avaliou-os quantitativamente por injeção sintética (M5) e cruzou as detecções com eventos reais e setores (M6). Os principais resultados parciais são:

- Infraestrutura com configuração centralizada, *seeds* fixas e proveniência documentada de cada hiperparâmetro, separando escolhas fundamentadas de valores provisórios.
- Quatro séries íntegras (3724 pregões, sem NaN), com anomalias reais já mapeadas como âncoras para a validação narrativa.

- Esclarecimento do caso AMER3: a hipótese de artefato de agrupamento foi refutada com os dados, e o ativo segue o pipeline padrão (Seção 6.3).
- Representação de entrada pronta: log-retornos normalizados em janelas de 30 passos, com split temporal e scaler restrito ao treino (sem vazamento).
- Quatro modelos treinados com parada antecipada e `val_loss` homogêneo; a sensibilidade do gargalo (`latent_dim`) mostrou-se plana, confirmando o valor 16 (Seção 7).
- Limiares de detecção implementados: sob mudança de regime, o estático satura (AMER3  $\approx 27\%$ ) enquanto o dinâmico causal se recalibra ( $\approx 14\%$ ), evidência empírica a favor do esquema dinâmico (Seção 8).
- *Pipeline* de avaliação quantitativa pronto: injeção sintética  $\rightarrow$  rotulagem por janela  $\rightarrow$  Precision/Recall/F1 (Seção 9). A magnitude absoluta provisória (0,15) produz *recall* baixo em ativos estáveis, evidenciando empiricamente a necessidade de calibrar o choque em  $k\sigma$  por ativo.
- Validação narrativa e setorial (Seção 10): eventos sistêmicos (COVID) disparam em todos os ativos e eventos idiossincráticos isolam-se no ativo afetado (AMER3 cobre 9/10 de seus eventos), confirmando a generalização cruzada por ativo.

**Próximos passos (M7 — Refinamento e fechamento).** Calibrar as magnitudes de injeção relativas ao desvio-padrão de cada ativo (ADR-0006) e conduzir o estudo de sensibilidade da janela dinâmica (`dynamic_window`  $\in \{126, 252, 504\}$ , ADR-0005), revalidando as métricas; estender a injeção a *volume spikes*; e consolidar as evidências no artigo final.

**Registro de decisões.** Todas as decisões de configuração estão documentadas como ADRs em `docs/adr/`. Este relatório é atualizado a cada fechamento de *milestone*, consolidando decisões, fontes, observações e conclusões para compor o artigo final.

## Referências

- [1] Martín Abadi et al. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. <https://www.tensorflow.org/>.
- [2] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
- [3] IEEE. Anomaly detection on Bitcoin values. In *Proceedings of the IEEE*, 2021.
- [4] Susan Li. Time series of price anomaly detection with LSTM. Towards Data Science, 2020. <https://medium.com/data-science/time-series-of-price-anomaly-detection-with-lstm-11a12ba4f6d9>.
- [5] Yifan Liu et al. Robust anomaly detection in financial markets using LSTM autoencoders and generative adversarial networks. *Journal of Economics, Finance and Accounting Studies*, 2025. OPAST Publishers.
- [6] Dejan Petrovic. Anomaly detection in stock price with LSTM autoencoder. GitHub, 2019. <https://github.com/dpetrovic89/Anomaly-Detection-in-Stock-Price-with-LSTM-Autoencoder>.
- [7] Venelin Valkov. Time series anomaly detection with LSTM autoencoders using Keras in Python. *curiously.com*, 2019. <https://curiously.com/posts/anomaly-detection-in-time-series-with-lstms-using-keras-in-python/>.