

Proposta de Trabalho Final

Disciplina: Redes Neurais

Detecção de Anomalias em Séries Temporais Financeiras Brasileiras com LSTM-Autoencoder

Integrantes: Ana Beatriz e Miguel Cerne | Período: 2026.1

1. Descrição do Problema

Mercados financeiros são sistemas complexos e não lineares, sujeitos a eventos extremos — crises econômicas, escândalos corporativos, choques políticos — que se manifestam como anomalias abruptas em séries temporais de preços e volumes. A detecção automática e precoce dessas anomalias tem alto valor tanto para investidores quanto para reguladores.

Este trabalho propõe a detecção de anomalias em séries temporais de ações listadas na B3 (Bolsa de Valores do Brasil) utilizando uma arquitetura LSTM-Autoencoder. A premissa central é que um modelo treinado exclusivamente em períodos de comportamento considerado "normal" aprende a reconstruir padrões típicos com baixo erro; quando confrontado com dados anômalos (movimentos atípicos, manipulações, eventos extremos), o erro de reconstrução aumenta significativamente, sinalizando a anomalia.

O diferencial desta proposta é o foco em ativos brasileiros, um contexto pouco explorado na literatura especializada, aliado à correlação sistemática entre as anomalias detectadas pelo modelo e eventos econômicos e políticos documentados no Brasil — permitindo uma interpretação qualitativa e quantitativa dos resultados.

2. Fonte dos Dados

Os dados serão obtidos por meio da biblioteca yfinance (Python), que fornece acesso gratuito a dados históricos do Yahoo Finance. Serão coletadas as séries diárias de:

- Preço de abertura, fechamento, máximo, mínimo e volume negociado
- Retorno diário logarítmico (feature principal de treinamento)

Os ativos selecionados para análise são:

- PETR4.SA — Petrobras PN (setor de energia/commodities)
- VALE3.SA — Vale S.A. (setor de mineração)
- AMER3.SA — Americanas S.A. (setor de varejo)
- ITUB4.SA — Itaú Unibanco (setor financeiro)

A escolha contempla setores distintos da economia brasileira, permitindo análise comparativa entre perfis de volatilidade diferentes. O período de coleta será de 2010 a 2024, abrangendo múltiplos ciclos econômicos e eventos de impacto.

3. Trabalhos Existentes na Área

3.1 Estudos Gerais com LSTM-Autoencoder

A abordagem de LSTM-Autoencoder para detecção de anomalias em séries temporais financeiras já foi explorada em diferentes contextos:

- **Time Series of Price Anomaly Detection with LSTM.** Li, S. (2020).
- Estudo com ações da Johnson & Johnson (NYSE) usando Yahoo Finance, treinando o modelo em dados históricos de 1985–2013 e detectando anomalias no período 2013–2020. É um dos trabalhos de referência mais replicados no tema — disponível no Medium e com código no GitHub.
- **Anomaly Detection in Stock Price with LSTM Autoencoder.** Petrovic, D. (GitHub).
- Repositório público com implementação end-to-end em Python/Keras para ações americanas. Amplamente replicado por estudantes e pesquisadores.
- **Anomaly Detection on Bitcoin Values.** IEEE (2021).
- Aplicação de LSTM para detecção de anomalias em preços de Bitcoin, com foco em captura de dependências temporais da criptomoeda.

3.2 Trabalhos Mais Recentes (2024–2025)

Estudos recentes elevaram a complexidade da abordagem base:

- **Robust Anomaly Detection in Financial Markets Using LSTM Autoencoders and GANs.** Liu et al. (2025).
- Framework híbrido que combina LSTM Autoencoder, GAN e One-Class SVM. Testado em seis categorias de ativos americanos e em regimes macroeconômicos distintos (Crise de 2008, COVID-19). Propõe injeção sintética de anomalias para avaliação quantitativa.
- **LSTM e DBSCAN para Bitcoin.** Springer Nature (2025).
- Combina LSTM com clustering DBSCAN para detectar anomalias em séries de preço do Bitcoin, com ênfase na melhoria de previsão por remoção de outliers.

3.3 Lacuna Identificada

A revisão da literatura indica que os trabalhos existentes se concentram majoritariamente em ativos dos mercados americano e de criptomoedas. O mercado brasileiro (B3) é sistematicamente sub-representado nesse tipo de análise. Adicionalmente, nenhum dos estudos identificados realiza correlação sistemática e

documentada entre anomalias detectadas por redes neurais e eventos históricos específicos do contexto brasileiro (intervenções do governo na Petrobras, escândalo da Americanas, crises eleitorais etc.).

4. O que Pretendemos Fazer

4.1 Metodologia

O pipeline do trabalho seguirá as etapas descritas abaixo:

- **download das séries via yfinance, cálculo de retornos logarítmicos, normalização MinMax, criação de janelas temporais deslizantes (window size a definir via validação).**
- **LSTM-Autoencoder treinado apenas em dados do período de "normalidade" (2010–2019), utilizando o erro de reconstrução (MSE) como métrica de aprendizado.**
- **aplicação do modelo nos dados de teste (2020–2024); anomalias identificadas quando o erro de reconstrução ultrapassa um limiar estatístico (percentil 95 do erro no conjunto de treinamento).**
- **avaliação de threshold estático versus threshold dinâmico (janela móvel percentílica) — contribuição metodológica original.**
- **construção de linha do tempo de eventos econômicos e políticos brasileiros documentados para verificar sobreposição com anomalias detectadas.**
- **comparação do comportamento do modelo em ativos de setores distintos (energia, mineração, varejo, financeiro).**

4.2 Avaliação

Como o problema é não supervisionado (sem rótulos reais de anomalia), a avaliação será feita por duas vias complementares:

- **verificação visual e narrativa de se as anomalias detectadas correspondem a eventos reais conhecidos (ex.: crash de março de 2020, caso Americanas em janeiro de 2023).**
- **injeção controlada de perturbações artificiais nas séries de teste (price shocks e volume spikes) para calcular métricas de Precision, Recall e F1-Score do detector.**
- **distribuição, histograma e evolução temporal do erro para cada ativo.**

5. Contribuição Original

Este trabalho se diferencia da literatura existente pelos seguintes aspectos:

- **aplicação em ativos nacionais, contexto pouco explorado na literatura de detecção de anomalias com deep learning.**

- **análise sistemática e documentada comparando os pontos de anomalia detectados com eventos econômicos e políticos nacionais específicos — contribuição inédita na literatura encontrada.**
- **estudo comparativo entre threshold estático (percentil fixo) e threshold dinâmico (percentil móvel em janela temporal), avaliando o impacto dessa escolha na sensibilidade do detector.**
- **avaliação de generalização do modelo entre setores econômicos distintos da B3, verificando se o comportamento anômalo é setor-específico ou generalizado.**

Nenhum dos trabalhos identificados na revisão bibliográfica combina esses quatro elementos simultaneamente.

6. Fonte dos Códigos

O desenvolvimento será predominantemente próprio, com as seguintes bases:

- **biblioteca yfinance (open source, PyPI).**
- **pandas, numpy, scikit-learn (normalização, métricas).**
- **implementação própria em Python com TensorFlow/Keras. Nos basearemos nas referências arquiteturais dos artigos citados (Li, 2020; Liu et al., 2025), mas a implementação, os dados e as análises serão originais.**
- **matplotlib e seaborn para gráficos de séries temporais, erros de reconstrução e linha do tempo de eventos.**
- **Google Colab (gratuito), com notebooks versionados no GitHub.**

Repositórios públicos de referência serão utilizados apenas como guia arquitetural, não como código a ser copiado. Todo o código produzido será original e documentado.